Instituto Tecnológico y de Estudios Superiores de Monterrey

Proyecto Integrador

Conclusiones Clave

08 de marzo de 2026

José Antonio Gómez Mora - A01374459

Alejandro Chávez Campos - A01374974

Laura Patricia Martínez Treviño - A01795967

Predicción del Precio de Aguacate en México mediante Modelos de Aprendizaje Automático..... 3
1. Introducción.....3
2. Criterios de Evaluación..... 3
2.1 Facilidad de uso..... 3
3. Análisis Comparativo.....4
4. Comparación de servicios clave.....5
5. Recomendación de Plataforma.....5
6. Arquitectura Sugerida y Costos asociados..... 6
7. Metodología de Selección: Matriz de decisión ponderada.....7
8. Conclusión.....9
Evaluación de Viabilidad del Modelo..... 10
1. El rendimiento del modelo, es lo suficientemente bueno para su implementación en producción?.....10
2. Existe margen para mejorar aún más el rendimiento?.....10
3. ¿Cuáles serían las recomendaciones clave para implementar la solución?.....10
4. ¿Qué tareas/procedimientos son accionables para las partes interesadas (stakeholders)?.....11
Referencias..... 12

Predicción del Precio de Aguacate en México mediante Modelos de Aprendizaje Automático

Proyecto de Maestría - Equipo de Predicción de Precios

---

1. Introducción

El objetivo de esta sección es analizar y comparar las principales plataformas de cómputo en la nube disponibles —Amazon Web Services (AWS), Microsoft Azure, Google Cloud Platform (GCP) e IBM Cloud (Watson)— para determinar cuál es la más adecuada para implementar una solución que permita:

- Ejecutar y actualizar un modelo de predicción de precios del aguacate
- Proveer inferencias periódicas para usuarios sin conocimientos técnicos
- Ofrecer visualizaciones claras y amigables
- Permitir el monitoreo y administración de tareas con facilidad
- Ajustarse a un presupuesto medio

Se evaluarán criterios como facilidad de uso, escalabilidad, servicios ofrecidos, costos asociados, experiencia de usuario y capacidades de integración.

---

2. Criterios de Evaluación

Para decidir la plataforma más adecuada se consideraron los siguientes factores:

2.1 Facilidad de uso

Capacidad de la plataforma para ser operada por usuarios no técnicos mediante:

- Interfaces gráficas intuitivas
- Automatización de tareas
- Documentación y soporte

2.2 Capacidades de Machine Learning

Presencia de servicios administrados que cubran

- Entrenamiento
- Reentrenamiento
- Implementación de modelos
- MLOps

2.3 Integración de Datos y Dashboards

Capacidad de integrar fuentes de datos, gestionar historiales y generar reportes o dashboards visuales

2.4 Monitoreo y Actualizaciones

Facilidad para monitorear estados de entrenamiento, inferencia, logs, y programar tareas de mantenimiento o reentrenamiento.

2.5 Costos

Relación costo-beneficio considerando carga ligera de datos, cálculos intermitentes y necesidades recurrentes no críticas.

---

3. Análisis Comparativo

A continuación se presenta un análisis sintético de cada plataforma con base en los criterios anteriores

3.1 Microsoft Azure

Fortalezas

- Alta facilidad de uso con UI limpia y amigable.
- Potente integración con Azure Machine Learning Studio, que permite gestionar modelos sin programar demasiado.
- Azure Power BI para visualización intuitiva y dashboards para usuarios no técnicos.
- Buen soporte de MLOps, pipelines y notificaciones.

Debilidades

- Costo, puede ser ligeramente superior a otras plataformas cuando se ejecuta infraestructura 24/7.
- Curva de aprendizaje sino se usa con herramientas visuales.

3.2 Amazon Web Services (AWS)

Fortalezas

- Ecosistema maduro con gran número de servicios.
- Servicios optimizados para Data Science: SageMaker ofrece entrenamiento, despliegue, y monitoreo en un solo lugar.
- Sistemas de monitoreo robustos con CloudWatch.
- Integración con base de datos escalables.

Debilidades

- Mayor complejidad inicial en comparación con Azure y GCP.

- La Interfaz y configuración puede abrumar a usuarios sin experiencia .
- Requiere decisiones técnicas de configuración.

3.3 Google Cloud Platform (GCP)

Fortalezas

- Vertex AI: Plataforma unificada para manejo completo de modelos.
- Buen balance entre simplicidad y potencia.
- Integración con BigQuery para análisis de datos.
- Costos competitivos para cargas ligeras.

Debilidades

- Menor presencia de mercado que AWS y Azure.
- Integración con visualización tipo BI - puede requerir herramientas adicionales -.

3.4 IBM Cloud (Watson)

Fortalezas

- Capacidad para trabajar de forma colaborativa.
- Servicios empresariales con soporte dedicado.

Debilidades

- Altos costos en cargas ligeras.
- Curva de aprendizaje y menos recursos comunitarios.
- Orientado a grandes empresas.

---

4. Comparación de servicios clave

Plataforma	Facilidad de uso	ML end-to-end	Amigable	Costos	Automatización de tareas
Azure	⭐⭐⭐⭐☆	⭐⭐⭐⭐☆	⭐⭐⭐⭐☆	$ $ $	⭐⭐⭐⭐☆
AWS	⭐⭐⭐☆☆	⭐⭐⭐⭐☆	⭐⭐⭐☆☆	$ $	⭐⭐⭐⭐☆
GCP	⭐⭐⭐⭐☆	⭐⭐⭐⭐☆	⭐⭐⭐☆☆	$ $ $	⭐⭐⭐⭐☆
IBM	⭐⭐☆☆☆	⭐⭐⭐☆☆	⭐⭐☆☆☆	$ $ $ $$	⭐⭐⭐☆☆

5. Recomendación de Plataforma

✴️Elección Recomendada: **Microsoft Azure**

Justificación

1. Facilidad de uso:
   Azure es particularmente intuitivo para usuarios que no poseen conocimientos técnicos profundos, gracias a interfaces gráficas y servicios de nivel visual, permitiendo crear pipelines, desplegar modelos y evaluar resultados sin dominar detalles de infraestructura.
2. Visualización integrada para usuarios finales:
   Con Power BI es posible crear dashboards interactivos para monitorear precios reales vs predichos, tendencias y métricas de desempeño que sean comprensibles para cualquier usuario.
3. Automatización de tareas y monitoreo sencillo:
   Azure ML incluye mecanismos integrados para programar entrenamientos y actualizaciones automáticas (MLOps) sin necesidad de scripts complejos.
4. Balance de costo y funcionalidad:
   Aunque no es la plataforma más barata, Azure ofrece alto valor por costo asociado, cuando se prioriza facilidad de uso, soporte y capacidades de BI.
5. Escalabilidad y crecimiento:
   Si la solución crece (más variables, más usuarios, nuevos modelos, más historial), Azure permite escalar sin reestructurar la arquitectura base.

6. Arquitectura Sugerida y Costos asociados

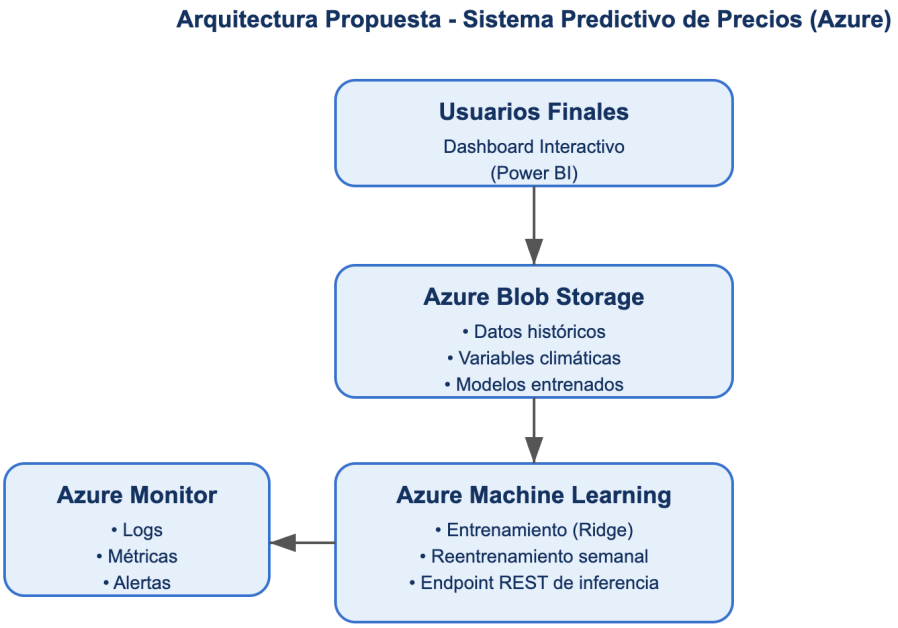

La solución propuesta para el despliegue del modelo predictivo de precios de aguacate se basa en servicios administrados de Microsoft Azure, seleccionados por su facilidad de uso para usuarios sin formación técnica, su integración nativa entre componentes y su capacidad para escalar según demanda.

La arquitectura general se compone de cuatro bloques principales:

1. Azure Data Storage
   Se utiliza para almacenar los datasets históricos, variables externas (temperatura, precipitación, importaciones), y los artefactos del modelo entrenado. Este servicio permite recuperar y versionar conjuntos de datos sin necesidad de infraestructura administrada manualmente.
2. Azure Machine Learning Service
   Proporciona un entorno visual y automatizable para entrenar y reentrenar modelos de Machine Learning. En particular, se configura con pipelines programados para ejecutar el reentrenamiento semanal del modelo de regresión Ridge utilizando los datos más recientes, generando un endpoint de inferencia REST para consultas puntuales.
3. Dashboard de Visualización (Power BI)
   Herramienta SaaS que facilita la construcción de reportes y dashboards interactivos. Conecta con los resultados de inferencia y los datos de almacenamiento para mostrar indicadores clave como precios predichos, tendencias y métricas estadísticas.
4. Azure Monitor
   Gestiona logs y métricas de actividad (tiempos de inferencia, tasa de fallos, uso de recursos) y permite configurar alertas que notifiquen sobre comportamientos fuera de lo esperado.

Estimación de Costos

El uso de una solución “serverless” o de plataformas gestionadas tiene un impacto directo en los costos operativos. Se estimó el gasto mensual basado en:

- Entrenamientos semanales que consumen pocas horas de CPU.
- Endpoint de inferencia activo permanentemente, para proveer predicciones bajo demanda.
- Monitoreo básico con generación de alertas y dashboards.
- Uso de Power BI para presentación de resultados, con licencias estándar.

El enfoque evita gestionar infraestructura compleja, reduce el trabajo operativo y permite enfocarse en la calidad del modelo y la interpretación de resultados.

Categoría	Azure	Uso estimado	Costo aproximado	Notas
Entrenamiento	Azure ML Compute	4 reentrenamientos / mes	$3 - $8	Instancia tipo CPU.
Inferencia API	Azure ML Endpoint	24x7 CPU	$108 - $216	Se puede auto-escalar
Monitoreo	Azure Monitor	Métricas y logs	$10 - $30	Dependiendo de alertas
Visualización	Power BI	Reporte mensual	$10 - $20	Licencias necesarias
Almacenamiento	Azure Blob Storage	≈10 GB	<$2	Muy barato para datasets pequeños

Total estimado mensual aproximado: $131 - $276 USD

7. Metodología de Selección: Matriz de decisión ponderada

7.1 Justificación metodológica

Para seleccionar objetivamente la plataforma adecuada, se utilizó la metodología de evaluación multicriterio, asignando ponderaciones a factores críticos del proyecto.

7.2 Definición de criterios

Se definieron 6 criterios estratégicos alineados con los objetivos del proyecto:

Criterio	Descripción	Peso (%)
Facilidad de uso	Interfaz intuitiva para usuarios no técnicos	25%
Integración ML	Soporte completo para entrenamiento, deployment y MLOps	20%
Visualización amigable	Calidad e integración de dashboards	15%
Automatización	Programación de reentrenamientos y monitoreo	25%
Costo estimado	Viabilidad dentro de presupuesto medio	15%
Escalabilidad futura	Capacidad de crecimiento	10%

Justificación: Se prioriza facilidad de uso porque el sistema esta orientado a usuarios sin perfil técnico.

7.3 Evaluación Cuantitativa

Se calificó cada proveedor en escala de 1 a 5:

(1 = muy bajo, 5 = excelente)

Plataforma	Facilidad	ML	Visualización	Automatización	Costo	Escalabilidad
Azure	5	4	5	4	3	4
AWS	3	5	4	5	4	5
GCP	4	4	3	4	5	4
IBM	2	3	2	3	2	3

7.4 Cálculo de puntaje ponderado

Multiplicamos cada cualificación por su peso.

Microsoft Azure: $(5\times0.25) + (4\times0.20) + (5\times0.15) + (4\times0.15) + (3\times0.15) + (4\times0.10)$
$= 1.25 + 0.8 + 0.75 + 0.6 + 0.45 + 0.4$
$= 4.25$

AWS: $(3\times0.25) + (5\times0.20) + (4\times0.15) + (5\times0.15) + (4\times0.15) + (5\times0.10)$
$= 0.75 + 1 + 0.6 + 0.75 + 0.6 + 0.5$
$= 4.20$

GCP: (4×0.25) + (4×0.20) + (3×0.15) + (4×0.15) + (5×0.15) + (4×0.10)
= 1 + 0.8 + 0.45 + 0.6 + 0.75 + 0.4
= 4.00

IBM:2.55

7.5 Resultado final

Plataforma	Puntaje Final
Azure	4.25
AWS	4.20
GCP	4.00
IBM	2.55

7.6 Interpretación de resultados

Aunque AWS presenta capacidades técnicas ligeramente superiores en ML y escalabilidad, Azure obtiene puntaje más alto debido a:

- Mayor facilidad de uso.
- Mejor integración con herramientas de visualización (Power BI).
- Mejor alineación con usuarios no técnicos

La diferencia entre Azure y AWS es pequeña (o.05), lo que indica que ambas plataformas son técnicamente viables. Sin embargo, el criterio estratégico principal del proyecto - usabilidad para usuarios finales - favorece a Azure.

8. Conclusión

La mejor combinación de simplicidad, potencia y escalabilidad es Microsoft Azure, decisión orientada a usuarios no técnicos, con presupuesto medio y con necesidad de visualizaciones claras y monitoreo automático.

Esta elección permite no solo implementar el modelo predictivo de precios de aguacate, sino también proporcionar una experiencia amigable y sostenible para quienes tomarán decisiones basadas en los resultados.

Evaluación de Viabilidad del Modelo

1. El rendimiento del modelo, es lo suficientemente bueno para su implementación en producción?

Parcialmente. Los modelos alternativos evaluados en este notebook (ExtraTrees, GaussianProcess, SVR, MLP) presentan un MAPE entre 16.78% y 36.56%, lo cual no es ideal para producción en un contexto de negociación de precios donde errores superiores al 10% pueden traducirse en pérdidas significativas para APEAJAL.

Sin embargo, estos resultados sirvieron como benchmark para identificar que:

- Los modelos más complejos (MLP, LSTM) no necesariamente superan a los más simples en series temporales cortas.
- Extra Trees fue el mejor modelo alternativo (MAPE 16.78%), pero aun así queda lejos del objetivo.
- El modelo Ridge Regression con datos filtrados exclusivamente para Jalisco (notebook 05) logró un MAPE de 5.93%, lo cual si es viable para producción. Esto confirma que la calidad y especificidad de los datos es más determinante que la complejidad del modelo.

Criterio de éxito: Un MAPE menor al 10% se considera aceptable para pronósticos de precios agrícolas. Ridge con datos de Jalisco cumple este criterio con margen.

2. Existe margen para mejorar aún más el rendimiento?

Si, existen varias oportunidades de mejora:

1. Incorporar más datos exógenos: Tipo de cambio USD/MXN actualizado, precios de aguacate en EE.UU. (Hass Avocado Board), y datos de oferta de competidores (Perú, Chile) podrían capturar dinámicas de mercado que los lags de precio no reflejan.
2. Aumentar la granularidad temporal: Pasar de datos mensuales a quincenales o semanales incrementa el número de observaciones y permitirá capturar patrones de corto plazo.
3. Ensambles híbridos: Combinar Ridge (bueno en tendencia) con modelos que capturen mejor la estacionalidad (como SARIMA o Prophet) podría reducir el error en meses de alta volatilidad.
4. Actualización continua: Implementar re-entrenamiento mensual conforme se disponga de nuevos datos para evitar degradación del modelo (concept drift).
5. Feature engineering avanzado: Variables como indicadores de sequía, heladas, o eventos de mercado (Super Bowl, Cinco de Mayo) podrían mejorar la predicción en meses específicos.

3. ¿Cuáles serían las recomendaciones clave para implementar la solución?

1. Usar Ridge Regression como modelo base en producción por su simplicidad, interpretabilidad y mejor desempeño (MAPE 5.93%).
2. Mantener el filtrado geográfico por Jalisco. Mezclar datos nacionales introduce ruido que triplica el error de predicción (MAPE 18.59% vs 5.93%).
3. Establecer un pipeline automatizado de ingesta de datos, feature engineering, predicción y reporte mensual.

4. Definir umbrales de alerta: Si el MAPE en producción supera el 10% durante 3 meses consecutivos, disparar re-entrenamiento del modelo.
5. Presentar predicciones con intervalos de confianza (no solo puntuales) para que las decisiones de negociación consideren el rango de incertidumbre.
6. Validar predicciones contra precios reales cada mes y mantener un dashboard de monitoreo del modelo.

4. ¿Qué tareas/procedimientos son accionables para las partes interesadas (stakeholders)?

Para el equipo directivo de APEAJAL:

- Utilizar los pronósticos mensuales como referencia en negociaciones con compradores, considerando el intervalo de confianza del 95%.
- En meses donde el modelo predice alza (típicamente enero-febrero), negociar contratos de venta anticipada a precios favorables.
- Monitorear la desviación entre precio real y pronosticado como indicador de cambios estructurales en el mercado.

Para el equipo de datos:

- Automatizar la recolección mensual de datos de precios, clima e importaciones.
- Re-entrenar el modelo trimestralmente o cuando el error acumulado supere el umbral definido.
- Explorar la incorporación de datos de tipo de cambio y precios internacionales para mejorar la precisión.

Para productores asociados:

- Planificar volúmenes de cosecha y almacenamiento basados en las tendencias de precio pronosticadas.
- Diversificar ventanas de venta: el modelo indica que los precios de inicio de año tienden a ser más altos, lo cual favorece la venta durante la temporada pico de Jalisco (octubre-febrero).

Referencias

[1] Amazon Web Services, “Amazon Web Services (AWS) - Cloud Computing Services.” https://aws.amazon.com/ (accessed Mar. 4, 2026).

[2] Microsoft, “Microsoft Azure.” https://azure.microsoft.com/es-es/ (accessed Mar. 4, 2026)..

[3] Google Cloud, “Google Cloud: Cloud Computing Services.” https://cloud.google.com/ (accessed Mar. 4, 2026).

[4] IBM, “IBM Watson.” https://www.ibm.com/mx-es/watson (accessed Mar. 4, 2026).